Vision Transformer

Model Overview

Model	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

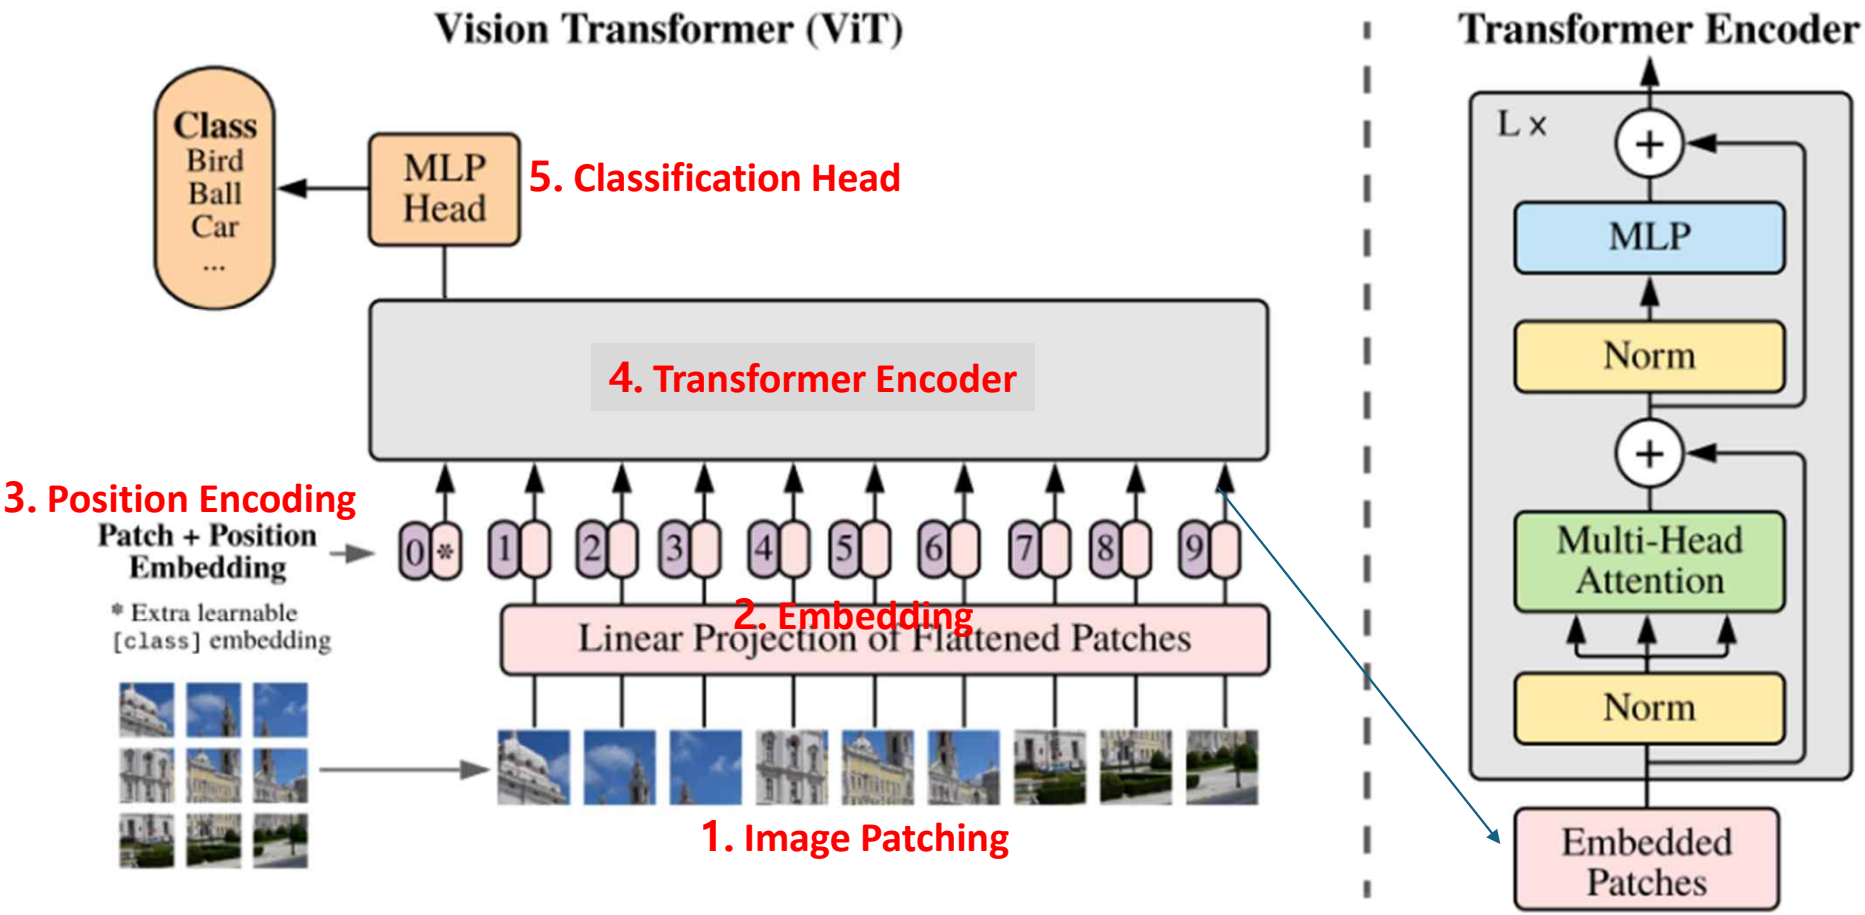

ViT의 작동 방식

1. **Image Patching**: 주어진 이미지를 여러 개의 고정 크기의 패치(patch)로 나눕니다. 예를 들어, 224×224 크기의 이미지를 16×16 크기의 패치로 나누면 총 196개의 패치가 생깁니다.
2. **Embedding**: 각 패치를 1D 벡터로 평탄화(flatten)한 후, 선형 임베딩(linear embedding) 레이어를 통과시켜 고정된 크기의 임베딩 벡터로 변환
3. **Position Encoding**: 각 패치의 위치 정보를 주입하기 위해 위치 인코딩(position encoding)을 추가. 이는 NLP에서의 Transformer와 동일한 개념.
4. **Transformer Encoder**: 앞서 생성한 임베딩 벡터들은 Transformer 인코더에 입력됩니다. Transformer 인코더는 여러 개의 attention 및 feed-forward 네트워크 레이어로 구성.
5. **Classification Head**: Transformer의 최종 출력은 분류 작업을 위한 MLP 레이어(또는 다른 헤더)에 입력

입력 Patch 구성

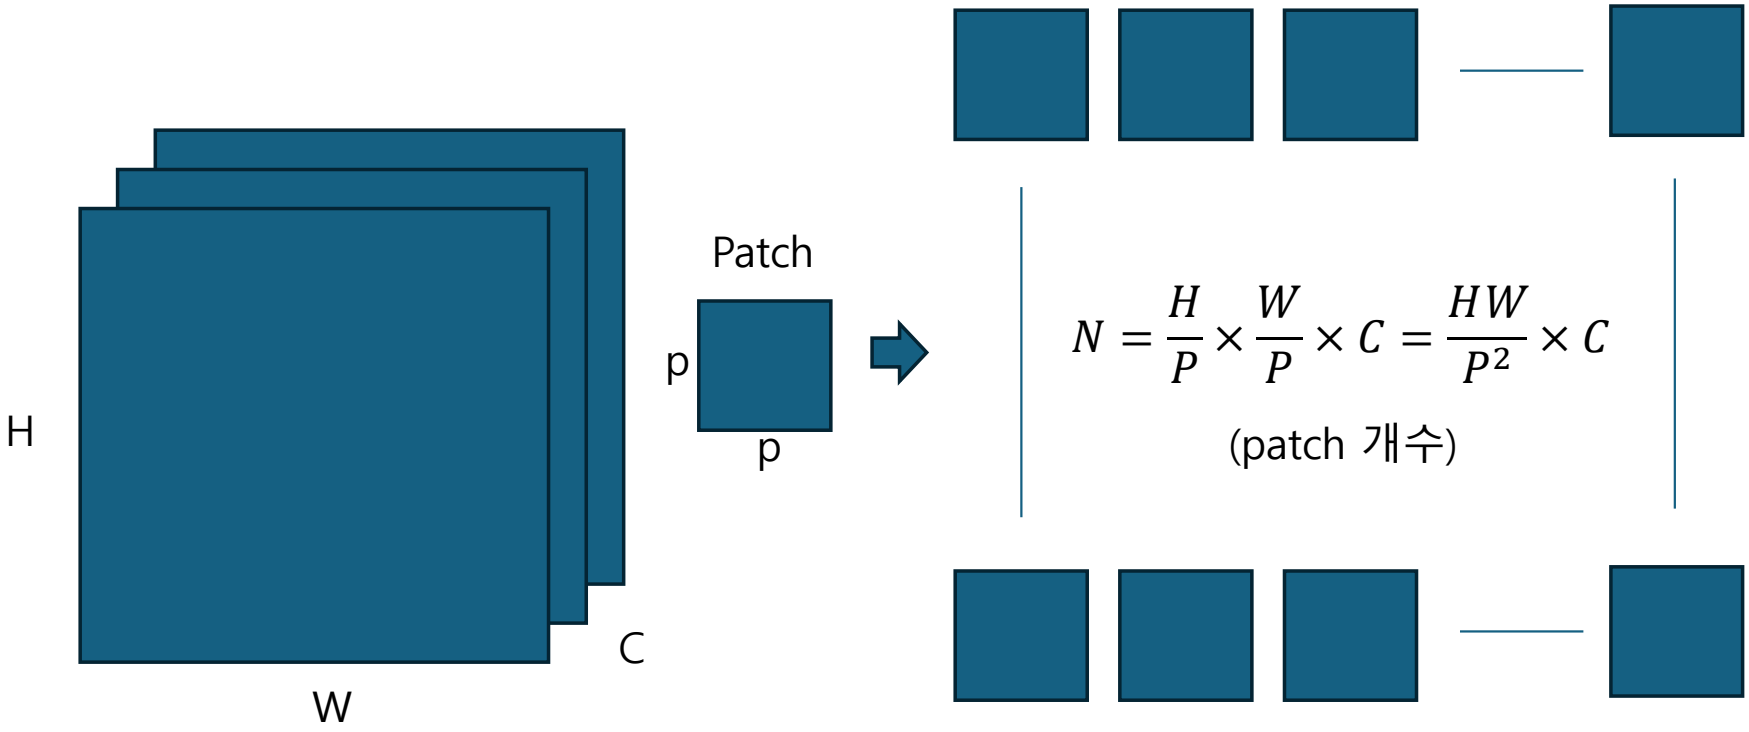
H
W
C
Patch
p
p
$N = \frac{H}{P} \times \frac{W}{P} \times C = \frac{HW}{P^2} \times C$
(patch 개수)

Linear Projection of Patch

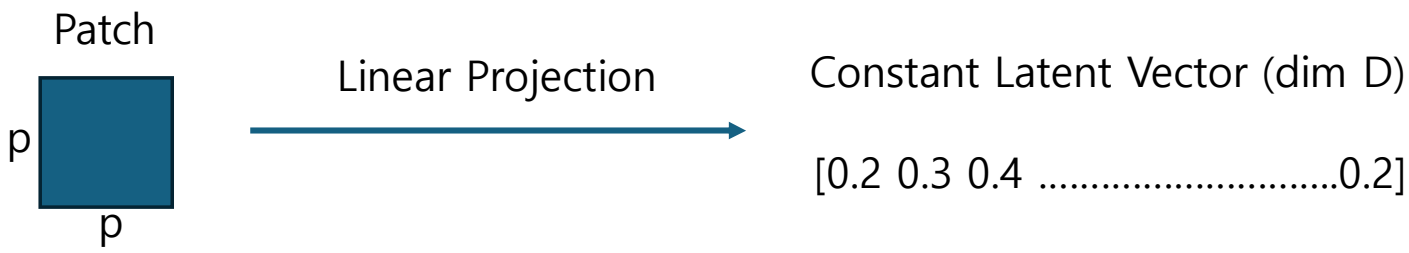

CLIP
(Contrasive Language-Image Pre-training)

Learning Transferable Visual Models From Natural Language Supervision

사용 dataset

- MS-COCO, Visual Genome: 고품질/소규모 데이터 (100,000개)
- YFCC100M (100M) → filtering 후 고품질 15M개 사용
- 인터넷에 공개되어 있는 400M개의 (image, text) pair로 새로운 dataset 구성
- 텍스트 query는 위키피디아에서 100번 이상 등장하는 단어 50만개로 구축
- 데이터 균형을 위해 query당 이미지-텍스트 pair 개수를 최대 2만개로 제한
- 위 3가지 데이터로 contrastive learning (대조학습) 수행

* constrasive learning 은 서로 다른 두 데이터 포인트가 얼마나 다른지 (또는 유사한지)를 비교하거나 측정하여 유사한 데이터 포인트들이 가까이 있도록 임베딩 공간을 구성

Data example

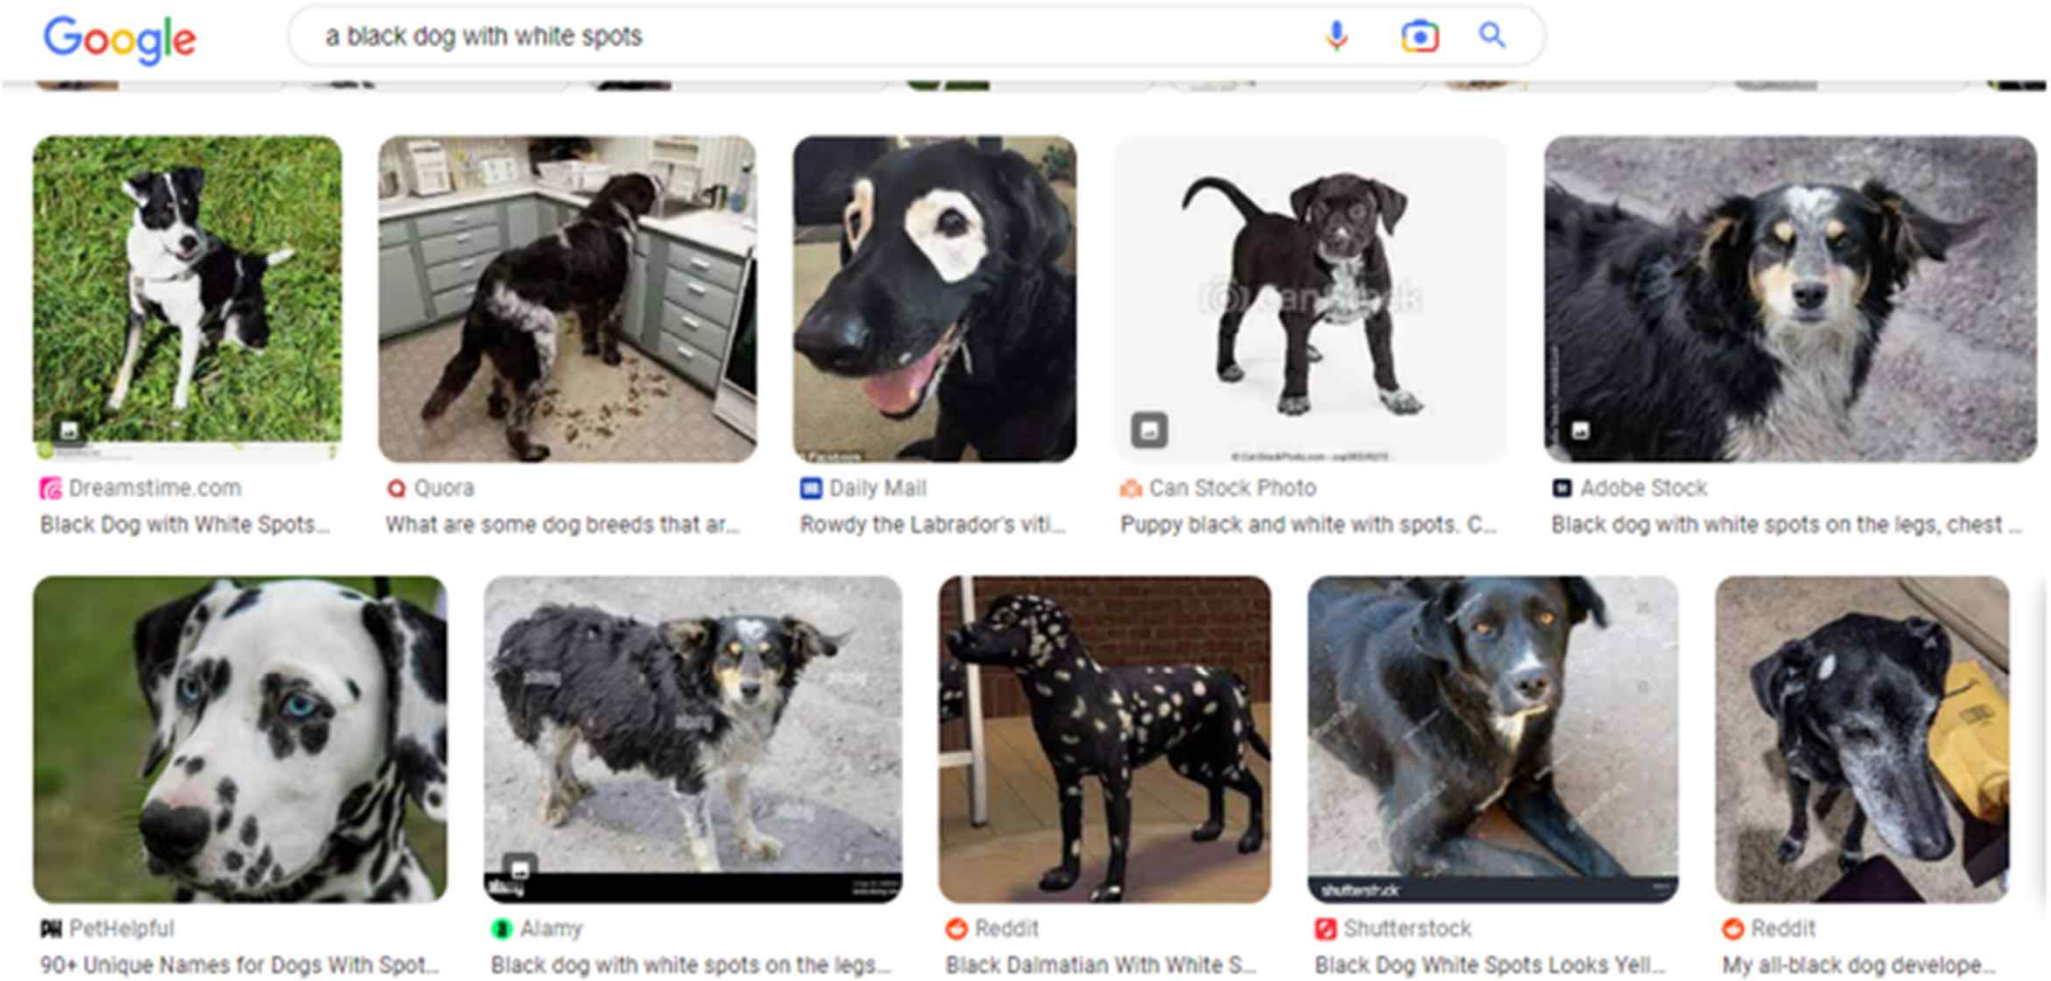

Contrasive Pre-Training

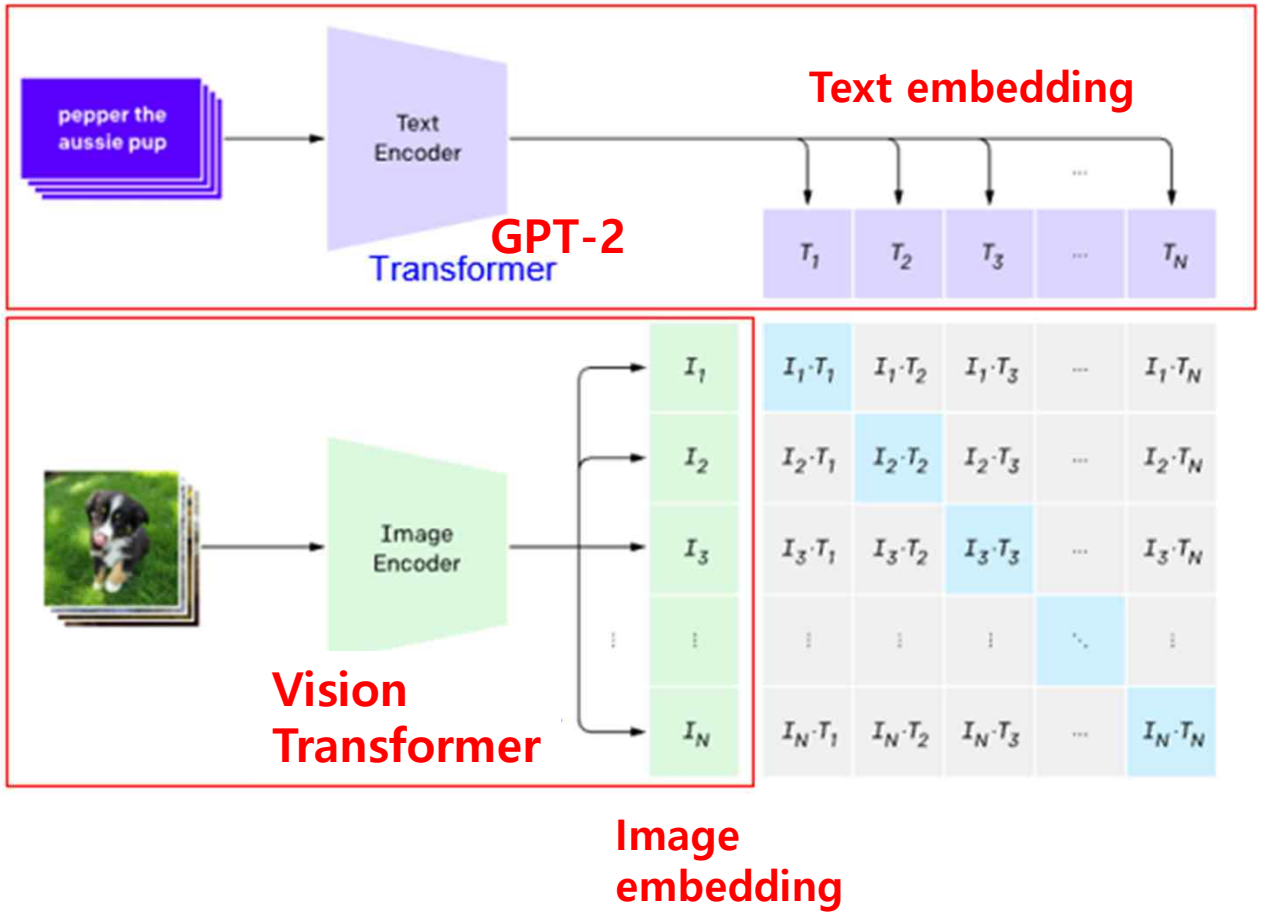

- N개의 이미지, 텍스트를 각각 encoder를 통과시켜 embedding vector 계산 (N: batch 사이즈)
- NxN matrix의 대각선 부분이 positive pair, 그 외 부분은 모두 negative pair
  (N개의 positive pair, N^2-N개의 negative pair)
- Positive pair의 cosine 유사도는 maximize 하고, negative pair의 cosine 유사도는 minimize 하도록 train

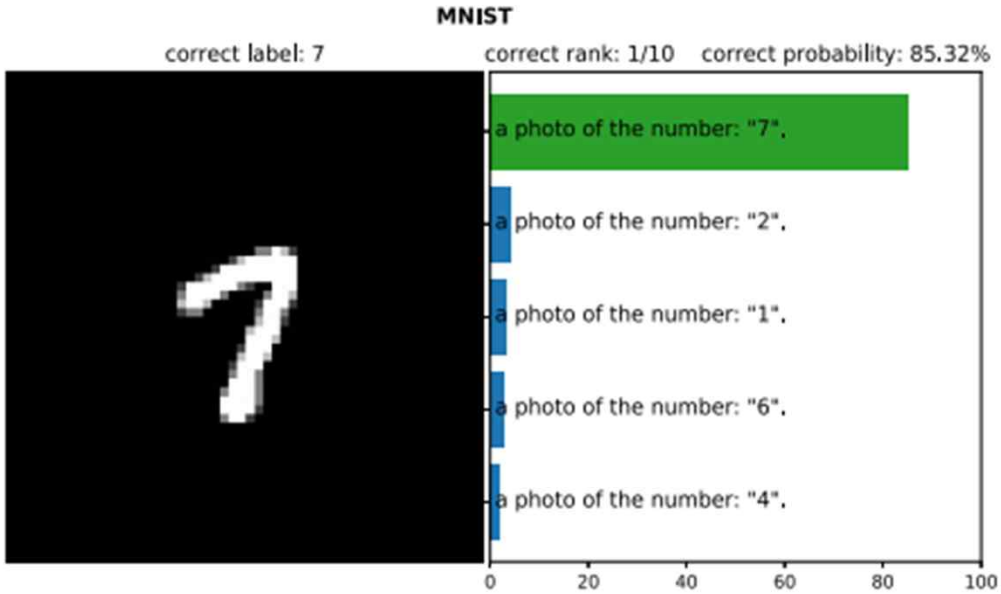
MNIST
correct label: 7
correct rank: 1/10
correct probability: 85.32%
a photo of the number: "7".
a photo of the number: "2".
a photo of the number: "1".
a photo of the number: "6".
a photo of the number: "4".
0
20
40
60
80
100

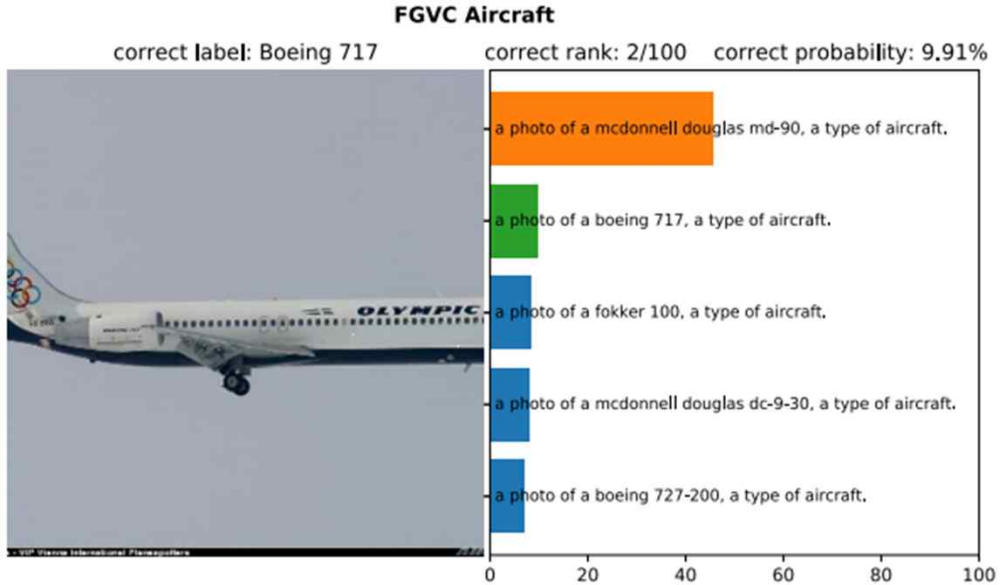
FGVC Aircraft
correct label: Boeing 717
correct rank: 2/100
correct probability: 9.91%
a photo of a mcdonnell douglas md-90, a type of aircraft.
a photo of a boeing 717, a type of aircraft.
a photo of a fokker 100, a type of aircraft.
a photo of a mcdonnell douglas dc-9-30, a type of aircraft.
a photo of a boeing 727-200, a type of aircraft.
0
20
40
60
80
100

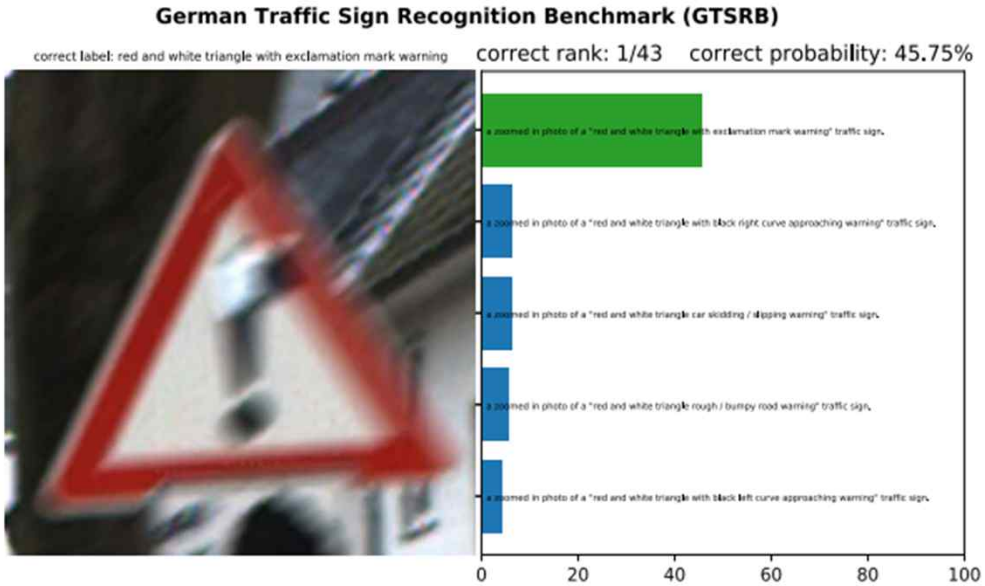
German Traffic Sign Recognition Benchmark (GTSRB)
correct label: red and white triangle with exclamation mark warning
correct rank: 1/43
correct probability: 45.75%
0
20
40
60
80
100

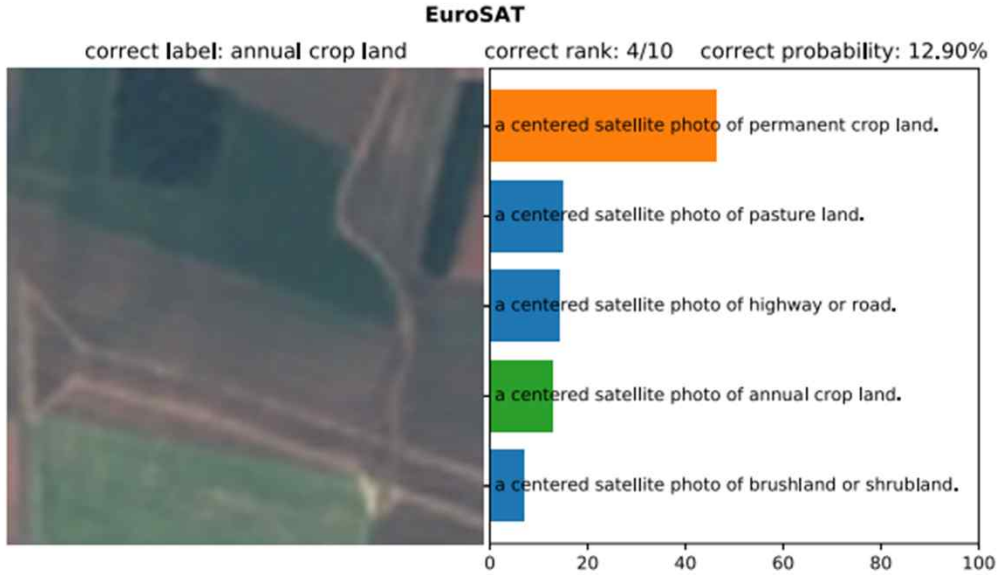
EuroSAT
correct label: annual crop land
correct rank: 4/10
correct probability: 12.90%
a centered satellite photo of permanent crop land.
a centered satellite photo of pasture land.
a centered satellite photo of highway or road.
a centered satellite photo of annual crop land.
a centered satellite photo of brushland or shrubland.
0
20
40
60
80
100

DALL-E2 Structure

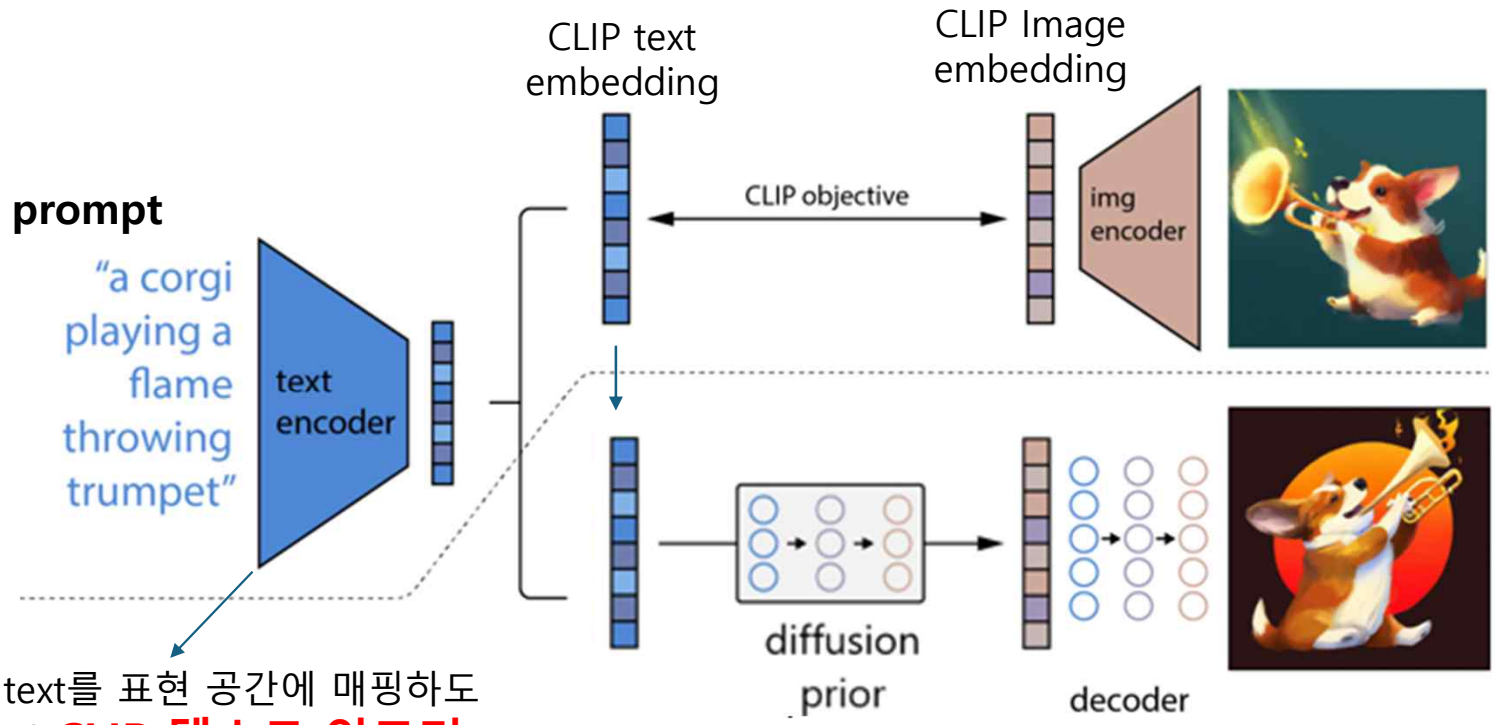

Text prompt

화염이 나오는 트럼펫을 부는 웰시코기

입력된 text를 표현 공간에 매핑하도록 훈련된 **CLIP 텍스트 인코더**

prior 라고 불리는 모델은 텍스트 인코딩에 포함된 프롬프트의 의미론적 정보를 캡처하여 해당 이미지 인코딩에 매핑하는 역할

이미지 디코더는 이 의미론적 정보의 시각적 표현인 이미지를 확률적으로 생성

→ **Diffusion model (GLIDE)**

점선 윗부분은 CLIP embedding 생성 pre-training

점선 아래 부분은 Text-to-Image 생성 diffusion Prior & Decoder

DALL-E2 학습 방법. (1단계) – CLIP 모델 학습

- DALL-E2는 OpenAI의 CLIP 모델을 이용하여 텍스트 의미론과 시각적 표현 사이의 연결을 학습. 즉, CLIP은 이미지가 주어진 캡션을 예측하는 대신 주어진 캡션이 이미지와 얼마나 관련이 있는지 학습

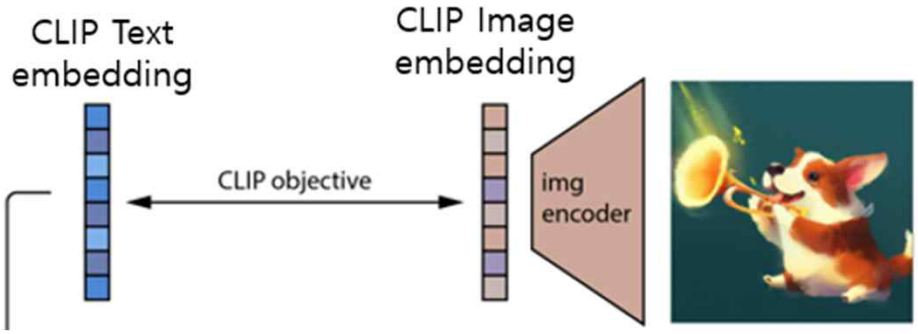

a corgi playing a flame throwing trumpet

(화염이 나오는 트럼펫을 부는 웰시코기)

DALL-E2 학습 방법. (2단계) – Diffusion model 학습

- 학습 후 CLIP 모델은 고정(frozen)되고 DALL-E 2는 다음 작업으로 이동
- CLIP이 학습한 이미지 인코딩을 뒤집어 이미지를 생성하는 방법을 학습

  → Diffusion Model(GLIDE)을 decoder로 이용하여 이미지 생성.

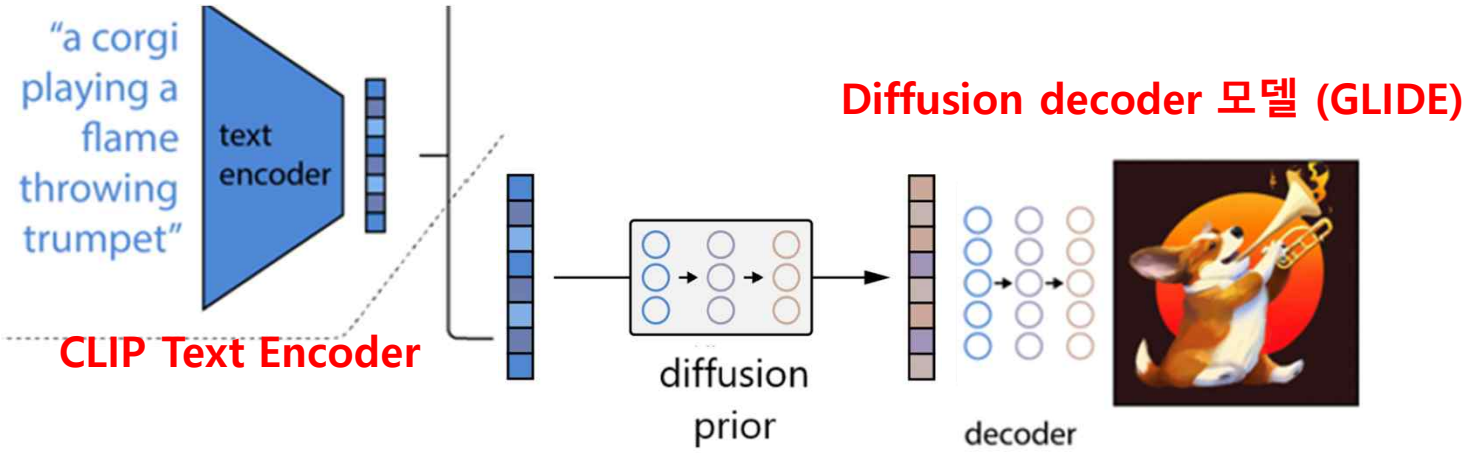

프롬프트 text를 CLIP의 text embedding을 사용하여 가장 가능성 높은
CLIP image embedding으로 mapping 하는 모델